

**TEMAS AVANZADOS DE
INTELIGENCIA
ARTIFICIAL
2026-1**

I. INFORMACIÓN GENERAL

CURSO	TEMAS AVANZADOS DE INTELIGENCIA ARTIFICIAL
CLAVE	1INF61
CRÉDITOS	3
HORAS DE DICTADO	CLASE: 3 Semanal EXAMEN:
HORARIO	TODOS
PROFESORES	EDWIN ALVAREZ MAMANI CESAR ARMANDO BELTRAN CASTAÑON

II. PLANES CURRICULARES DONDE SE DICTA EL CURSO

ESPECIALIDAD	ETAPA	NIVEL	CARÁCTER	REQUISITOS
INGENIERÍA INFORMÁTICA	PREGRADO EN FACULTAD	0	ELECTIVO	1INF24 INTELIGENCIA ARTIFICIAL [07]

Tipos de requisito

- 04 = Haber cursado o cursar simultáneamente
- 05 = Haber aprobado o cursar simultáneamente
- 06 = Promedio de notas no menor de 08
- 07 = Haber aprobado el curso

III. DESCRIPCIÓN DEL CURSO

Los estudiantes, al culminar el curso, comprenderán los fundamentos teóricos y prácticos de Graph Machine Learning (Graph ML) para el análisis y generación de conocimiento a partir de datos representados como grafos (redes). En este contexto, el Graph Machine Learning se presenta como el marco metodológico para el aprendizaje sobre redes, orientado a al diseño y aplicación de modelos computacionales que permitan analizar patrones, relaciones e interdependencias entre entidades en diversos dominios. Se analizarán modelos inteligentes fundamentados en Graph embeddings tales como DeepWalk, Node2vec, Graph Convolutional Networks (GCN) Graph Attention Networks (GAT) y Graph Autoencoders (GAE). Asimismo, se abordarán tareas de node classification, link prediction, graph classification y community detection, así como técnicas de preprocesamiento y generación de embeddings a nivel de nodos , aristas y grafos a fin de mejorar el desempeño de los modelos.

IV. SUMILLA

El curso es de naturaleza teórica cuyo propósito es que el estudiante comprenda herramientas de inteligencia artificial modernas aplicadas a diferentes contextos.

V. OBJETIVOS

FACULTAD DE CIENCIAS E INGENIERÍA
1INF61 - TEMAS AVANZADOS DE INTELIGENCIA ARTIFICIAL

El objetivo central de este curso es estudiar los fundamentos y aplicaciones del Graph Machine Learning, que permitan modelar datos/problemas como grafos y aplicar técnicas modernas de Graph ML para resolver problemas en diversos dominios.

Este curso permite:

• Comprender y manipular estructuras de grafos desde una perspectiva matemática y computacional.

• Estudiar e implementar modelos clásicos de aprendizaje en grafos (Shallow embeddings).

• Generar representaciones de nodos, aristas y grafos completos.

• Estudiar, implementar modelos de Graph Neural Networks (GNN).

• Evaluar modelos de GNN con métricas adecuadas.

• Aplicar Graph ML a problemas reales.

• Interpretar y analizar resultados de modelos basados en grafos.

VI. PROGRAMA ANALÍTICO

UNIDAD 1 INTRODUCCIÓN (3 semanas)

Objetivos: Conocer los objetivos, alcance y metodología del curso. Conocer la motivación para el Machine Learning en grafos y sus diferencias con el Machine Learning tradicional.

Contenido: Motivación, ¿todo está conectado?. Datos estructurados, no estructurados y semi-estructurados. Grafos como representación de datos relacionales. Perspectiva general de Graph Machine Learning. Casos de estudio y aplicaciones.

UNIDAD 2 INTRODUCCIÓN A LA TEORÍA DE GRAFOS (3 semanas)

Objetivos: Comprender los conceptos fundamentales de la Teoría de Grafos. Analizar cómo los grafos modelan relaciones en problemas reales.

Contenido: Definición formal de grafos. Representaciones computacionales básicas.

UNIDAD 3 FAMILIA DE GRAFOS (3 semanas)

Objetivos: Conocer y diferenciar las principales tipos de grafos. Comprender las propiedades estructurales y aplicabilidad de cada tipo en problemas reales.

Contenido: Concepto de los tipos de grafos y criterios de clasificación. Propiedades de los distintos tipos de grafos.

UNIDAD 4 ALGORITMOS SOBRE LOS GRAFOS (3 semanas)

Objetivo: Comprender los principales algoritmos fundamentales sobre grafos. Analizar su utilidad para el análisis y procesamiento de redes en problemas reales. Contenido: Recorridos en grafos. Caminos y distancias en grafos. Conectividad y componentes conexas.

UNIDAD 5 MÉTRICAS EN GRAFOS (3 semanas)

Objetivo: Comprender las principales métricas utilizadas para caracterizar la estructura de un grafo. Analizar la interpretación y utilidad de dichas métricas en el análisis de grafos.

Contenido: Métricas a nivel de nodos. Métricas a nivel de aristas. Métricas a nivel de grafos. Interpretación de métricas en aplicaciones.

UNIDAD 6 INTRODUCCIÓN A GRAPH MACHINE LEARNING (3 semanas)

Objetivo: Comprender los fundamentos del Graph ML como paradigma de aprendizaje sobre los grafos. Diferenciar formalmente entre aprendizaje supervisado y aprendizaje no supervisado en grafos. Identificar las tareas típicas de aprendizaje en grafos y sus métricas de evaluación.

Contenido: Introducción al Graph Machine Learning. Aprendizaje supervisado y aprendizaje no supervisado en grafos. Tareas típicas: node classification, link prediction y graph classification. Métricas de evaluación. Taxonomía de Graph Machine Learning.

UNIDAD 7 MÉTODOS CLÁSICOS (SHALLOW EMBEDDINGS) (3 semanas)

Objetivo: Estudiar los fundamentos matemáticos y algorítmicos de los métodos clásicos de aprendizaje de representaciones en grafos (shallow embeddings), con énfasis en DeepWalk y Node2Vec.

Contenido: Introducción formal a graph embeddings. fundamentos y funcionamiento de DeepWalk y Node2Vec. Visualización básica de embeddings.

UNIDAD 8 MÉTODOS AVANZADOS (GRAPH NEURAL NETWORKS) (3 semanas)

FACULTAD DE CIENCIAS E INGENIERÍA
1INF61 - TEMAS AVANZADOS DE INTELIGENCIA ARTIFICIAL

Objetivos: Comprender los fundamentos conceptuales y formales de las Graph Neural Networks (GNN) como modelos de aprendizaje sobre estructuras de grafos, sus principios de propagación de información y sus principales variantes.

Contenido: Introducción a Graph Neural Networks. Paradigma de Message Passing. El problema de over-smoothing. Aplicaciones típicas.

UNIDAD 9 GRAPH CONVOLUTIONAL NETWORKS (GCN) (3 semanas)

Objetivos: Comprender la formulación matemática de las Graph Convolutional Networks y su aplicación en clasificación de nodos.

Contenido: Regla de propagación de GCN. Caso de estudio: clasificación de nodos.

UNIDAD 10 GRAPH ATTENTION NETWORKS (GAT) (3 semanas)

Objetivos: Comprender el mecanismo de atención en grafos y su formulación matemática.

Contenido: Regla de propagación con atención. Caso de estudio: clasificación de nodos.

UNIDAD 11 GRAPH ISOMORPHISM NETWORKS (GIN) (3 semanas)

Objetivos: Estudiar el poder expresivo de GIN y su relación con el test de Weisfeiler-Lehman.

Contenido: Regla de propagación de GIN. Caso de estudio: clasificación de grafos.

UNIDAD 12 GRAPH AUTOENCODERS (GAE/VGAE) (3 semanas)

Objetivos: Comprender modelos autoencoder para aprendizaje no supervisado en grafos.

Contenido: Regla de propagación en el encoder. Decodificador para reconstrucción de aristas. Caso de estudio: detección de comunidades y link prediction.

UNIDAD 13 GNN EN SISTEMAS DE RECOMENDACIÓN (3 semanas)

Objetivos: Reconocer ámbitos de aplicación de las Graph Neural Networks en sistemas de recomendación modelados mediante estructuras de grafos.

Contenido: Sistemas de recomendación representados como grafos relacionales. Integración de información estructural mediante GNN. Caso de uso: aplicación de GNN en un sistema de recomendación.

UNIDAD 14 GNN PARA DETECCIÓN DE ANOMALÍAS (3 semanas)

Objetivos: Reconocer ámbitos de aplicación de las Graph Neural Networks en la identificación de comportamientos anómalos en datos representados como grafos. Contenido: Detección de patrones inusuales en redes relacionales. Identificación de nodos con comportamiento estructural atípico en grafos. Caso de uso: aplicación de GNN en la identificación de comportamientos anómalos en grafos.

VII. METODOLOGÍA

Las sesiones de clase se realizarán de manera expositiva por parte del docente realizando algunas actividades a ser trabajadas con los estudiantes. Las presentaciones utilizadas en las sesiones de clases estarán disponibles previamente en el Campus Virtual PUCP. Se realizará un trabajo individual cuya finalidad es desarrollar un proyecto aplicando alguno de los modelos presentados en el curso.

VIII. EVALUACIÓN

Sistema de evaluación

Nº	Codigo	Tipo de Evaluación	Cant. Eval.	Forma de aplicar los pesos	Pesos	Cant. Eval. Eliminables	Consideraciones adicionales	Observaciones
1	Ta	Tarea académica	2	Por Evaluación	Ta1=20 Ta2=30			
2	Ex	Examen	2	Por Evaluación	Ex1=25 Ex2=25			

Modalidad de evaluación: 1

Fórmula para el cálculo de la nota final

$$(20Ta_1 + 30Ta_2 + 25Ex_1 + 25Ex_2) / 100$$

Aproximación de la nota final Redondeado 0 decimales.

Consideraciones adicionales

- Lineamientos sobre el uso de la IA.

El uso de herramientas de Inteligencia Artificial Generativa deberá ser declarado y citado en las actividades o trabajos que el docente indique, conforme a las normas correspondientes, y debidamente justificado. De ser necesario, el docente podrá solicitar el reporte de los prompts utilizados, los cuales deberán adjuntarse como anexo al trabajo. En caso contrario, se considerará como una falta a la ética académica y se procederá de acuerdo con los lineamientos institucionales existentes para estos casos.

IX. BIBLIOGRAFÍA

Referencia obligatoria

- Libro
Broadwater, W. Stillman N. (2024)
Neural Networks in Action.
- Libro
Gross, J. L., Yellen, J., Anderson, M. (2023)
Graph Theory and Its Applications.
- Libro
Labonne, M. (2023)
Hands-On Graph Neural Networks Using Python.
- Libro
Saoub, K. R. (2021)
Graph Theory: An Introduction to Proofs, Algorithms, and Applications.
- Libro
Van Steen, M. (2010)
Graph Theory and Complex Networks: An Introduction.

X. POLÍTICA CONTRA EL PLAGIO

Para la corrección y evaluación de todos los trabajos del curso se va a tomar en cuenta el debido respeto a los derechos de autor, castigando severamente cualquier indicio de plagio con la nota CERO (00). Estas medidas serán independientes del proceso administrativo de sanción que la facultad estime conveniente de acuerdo a cada caso en particular. Para obtener más información, referirse a los siguientes sitios en internet

www.pucp.edu.pe/documento/pucp/plagio.pdf